基于关联规则、协同过滤与学习排序的 H&M 个性化商品推荐

吕梦月 梁潇颖 郑旭阳

计算机科学与技术学院

2026 年 10 月 30 日

摘要

时尚商品推荐需同时利用用户历史偏好、近期热度与商品间联系。本文在 H&M 离线交易数据上实现“多路召回—学习排序”两阶段推荐流程：从约 10.5 万件商品中为每位目标顾客生成至多 100 件候选，再由 LambdaRank 选取前 12 件。召回阶段融合时间衰减复购、同天购物篮关联规则、SVD 隐式协同过滤、年龄分群热门与近 7 天全局热门五路信号，排序阶段使用 31 维特征训练 LightGBM 排序模型。在统一验证集上，最终模型 MAP@12 为 0.038758，较两组基线分别提升 39.75% 与 55.57%。

1 引言

1.1 研究背景与问题定义

随着线上时尚零售商品数量和用户选择空间不断扩大，平台需要根据用户的历史行为，在有限的推荐位中优先展示更可能被购买的商品。H&M 数据集记录了顾客、商品、交易日期、价格、销售渠道以及商品和顾客属性，为分析用户偏好、商品热度和商品间关联提供了基础。本文关注的问题是：给定用户在历史区间内的交易记录及可用属性，如何预测其目标周可能购买的商品，并为每位用户生成一个长度为 12 的个性化推荐列表。

该问题同时具有推荐场景中的几个典型难点：交易行为高度稀疏，用户购买频率差异明显；商品存在明显的长尾分布，新商品缺少历史反馈；用户偏好还会受到近期复购、同篮搭配、年龄群体和销售渠道等因素影响。因此，单一的热门商品规则或简单的历史复购规则难以兼顾覆盖率与排序质量。本文以目标周真实购买商品作为 Ground Truth，通过探索分析和模式挖掘提取行为规律，再将这些规律转化为多路候选召回信号和学习排序特征，最终比较规则基线与 LambdaRank 模型的推荐效果。

1.2 任务与挑战

预测对象是用户下一周可能购买的商品，输出按得分降序排列的 12 位商品编号。仅推荐热门商品难以满足多样需求，仅推荐历史购买又难以发现新品，因此采用先扩大候选覆盖、再统一排序的两阶段结构。

1.3 总体方案

原始交易与属性数据经规范化后，通过探索分析识别购买频次、近期行为、商品共现、类目与价格偏好；本文将上述发现具体落实为召回规则和排序特征；最后以目标周真实购买为标签训练排序模型并评价推荐列表。本文主要完成三方面工作：一是五路召回的信号构造与融合；二是 31 维排序特征体系；三是在同一验证用户集合与相同 Top-12 截断下对比基线与最终模型。

2 相关工作

热门推荐和基于规则的方法是推荐系统中较为基础的方案，通常根据商品的历史销量、近期热度或用户最近购买记录生成推荐列表。此类方法实现简单且具有较好的可解释性，但个性化能力有限。

协同过滤通过用户—商品交互关系挖掘相似用户或相似商品。Sarwar 等人提出的 Item-based Collaborative Filtering 方法通过计算商品之间的相似性进行推荐，是经典的商品协同过滤方法之一 [2]。矩阵分解方法则将用户和商品表示为低维潜在向量，Koren 等人系统总结了矩阵分解在推荐系统中的应用 [3]。本文使用的 SVD 隐式协同过滤召回属于这一类方法。

购物篮分析通过挖掘商品之间的共同出现关系发现潜在搭配。Agrawal 和 Srikant 提出的 Apriori 算法是关联规则挖掘领域的经典工作，利用频繁项集进一步生成关联规则 [1]。本文的同天购物篮共现规则借鉴了这一思想，但采用了面向候选召回的简化实现。

在候选商品生成后，还需要对候选进行排序。学习排序方法将推荐任务转化为排序问题，能够综合利用用户、商品和交互特征。RankNet 提出了基于成对样本的排序学习思想 [4]，LambdaRank 进一步将排序评价指标融入梯度计算过程 [5]。本文使用 LightGBM LambdaRank 对多路召回产生的候选商品进行统一排序。

综上，已有研究分别从热门程度、协同关系、商品共现和学习排序等角度解决推荐问题。本文结合这些方法，构建“多路召回 + 学习排序”的两阶段推荐框架，以同时利用用户近期偏好、商品搭配关系、群体偏好和全局热度。

3 数据说明与预处理

3.1 数据组成

表 1: 原始数据规模与用途

数据表	行数	字段数	作用
交易表	31,788,324	5	日期、顾客、商品、价格和渠道
顾客表	1,371,980	7	年龄、会员及订阅等属性
商品表	105,542	25	品类、颜色、部门和描述等
提交示例表	1,371,980	2	目标顾客与输出格式

交易覆盖 2018 年 9 月 20 日至 2020 年 9 月 22 日，通过顾客编号与商品编号连接属性表。

3.2 清洗策略

商品编号统一为 10 位字符串以避免前导零丢失；顾客编号末 16 位十六进制转为无符号 64 位整数键，并验证无压缩键碰撞。日期、价格、渠道转为对应类型，检查非法值与关联表未知编号。顾客类别缺失标记为 UNKNOWN，年龄保留可空整数，商品描述缺失填空串（年龄缺失 15,861 条，描述缺失 416 条）。质量检查中非法日期、非法价格、非法渠道、未知顾客、未知商品均为 0。

两套口径的区分。 同日同商品多件交易 5,518,811 条在清洗阶段**保留**，用于频次统计；购物篮挖掘时对篮内商品**去重**，使共现次数表示共同出现的篮数。原始商品文件虽为 CSV 扩展名，实为 ZIP 内容，按文件头识别；大交易表分块处理后以 Parquet 存储。

4 探索性分析：从证据到方法选择

本节按“交易节律—商品分布—用户行为”三组展开，每图后给出其对后续方法的具体指向。

4.1 交易节律

日交易量与价格总和波动明显（图1），近期窗口可提供全历史均值无法反映的趋势信号，据此设置近 7 天全局热门通道；月份渠道占比变化（图9）说明渠道结构具时间依赖性；星期交易量存在差异（图10），作为购买节律的描述性证据。

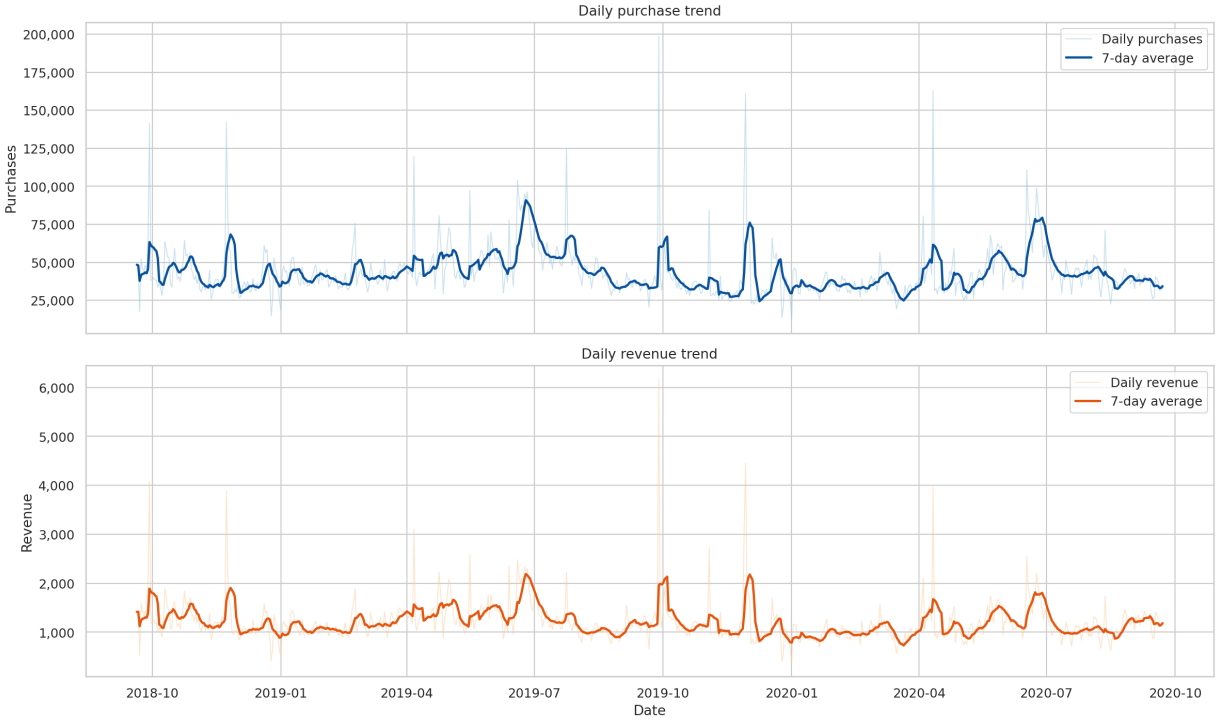


图 1: 日交易量及价格总和

4.2 商品分布

销量排名曲线快速下降而累计覆盖缓慢增加（图2），说明少量热门无法覆盖全部需求，热门通道需要与个性化通道配合；上装与下装贡献较多交易（图3），支持构建用户品类亲和特征；大

类交易规模差异明显（图11），整体热门易受主流大类影响；黑、白等颜色购买量较高（图12），可为稀疏行为提供补充；品类渠道构成不同（图13），表明渠道与商品类型有统计联系；价格分布集中且长尾（图14），本文据此用用户中位价和价格比刻画价格匹配。

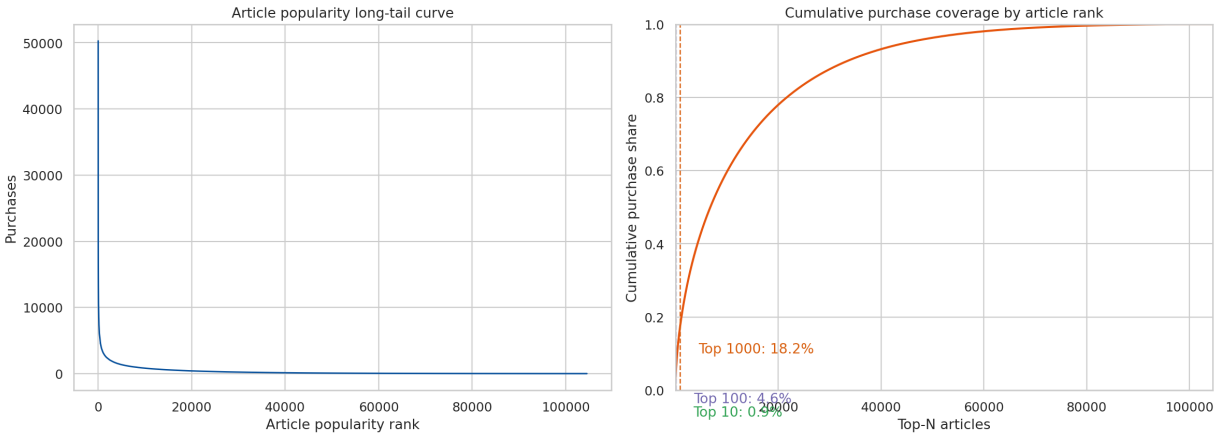


图 2: 商品销量长尾

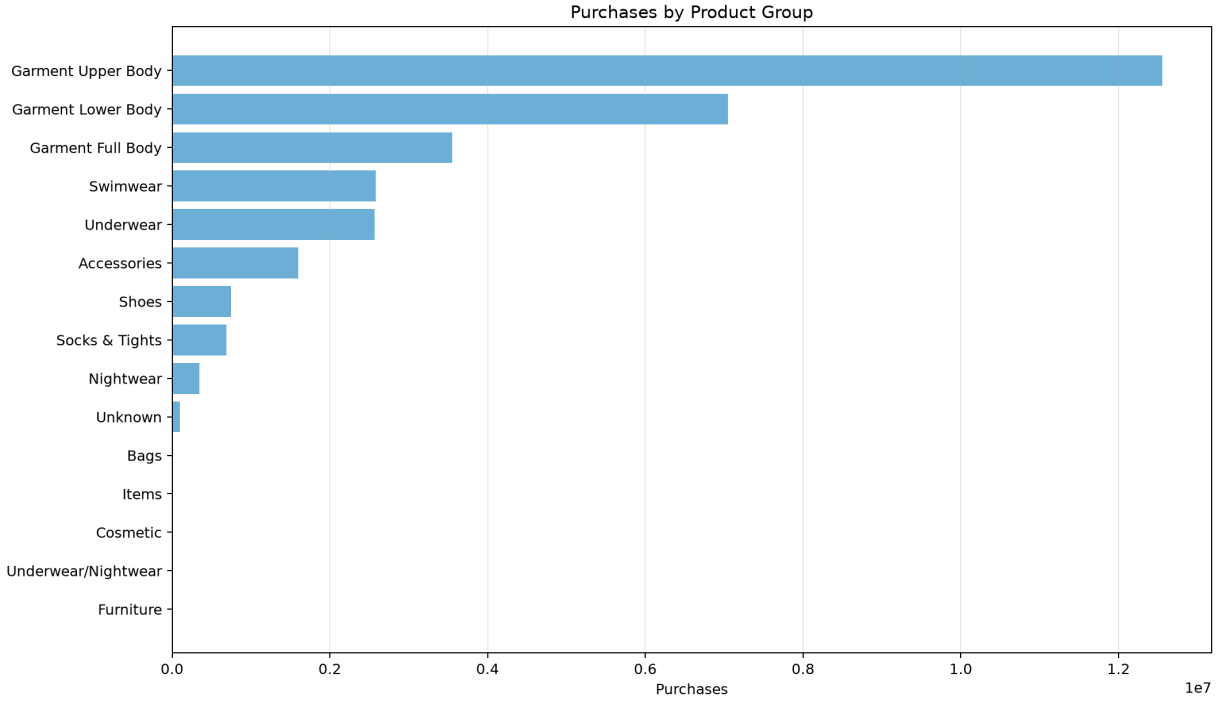


图 3: 品类购买量

4.3 用户行为

高活跃用户贡献交易比例较高而多数用户行为有限（图4），因此建模时需兼顾行为稀疏用户；购物篮多以少量商品组成但多商品篮足以支持共现挖掘（图5）；同商品购买间隔与用户总体访问间隔不同（图6），支持分别刻画复购与活跃；年龄组规模与覆盖率不同（图7），基于此设置年龄分群热门通道；会员与订阅状态和购买强度相关但不可推断因果（图15）；更长窗口提高覆盖率而短窗口更贴近目标周（图16），存在覆盖与时效权衡；大量顾客近期度较长（图17），仅用最近一

周历史会遗漏用户，因此复购窗口取近 180 天。

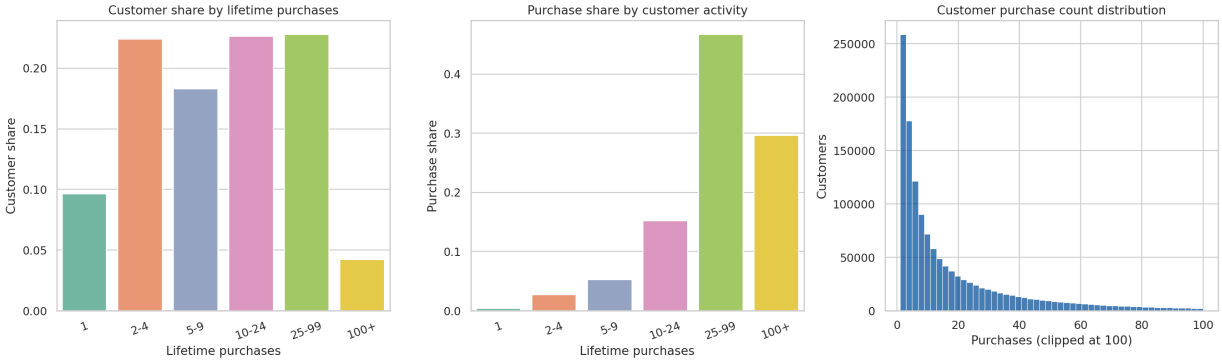


图 4: 用户活跃度分布

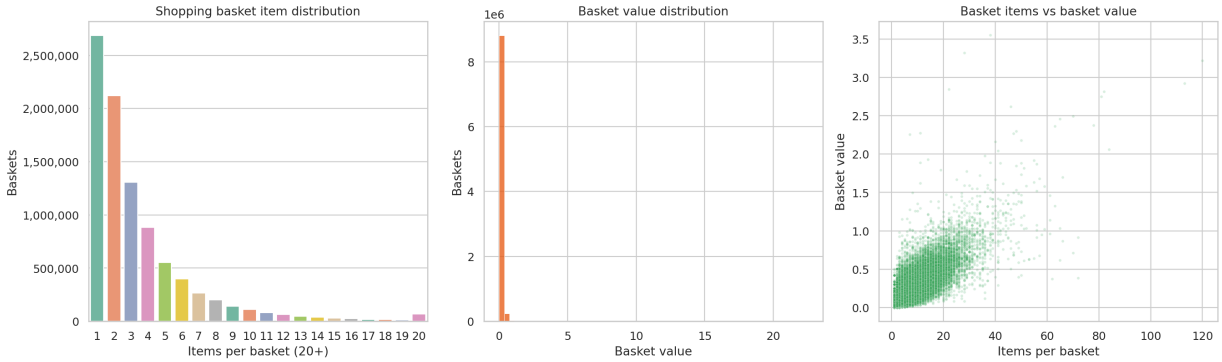


图 5: 购物篮规模

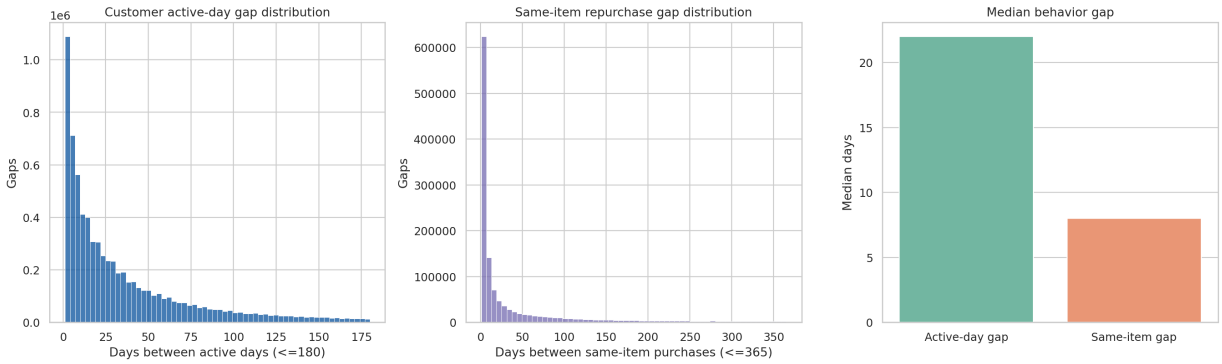


图 6: 购买间隔

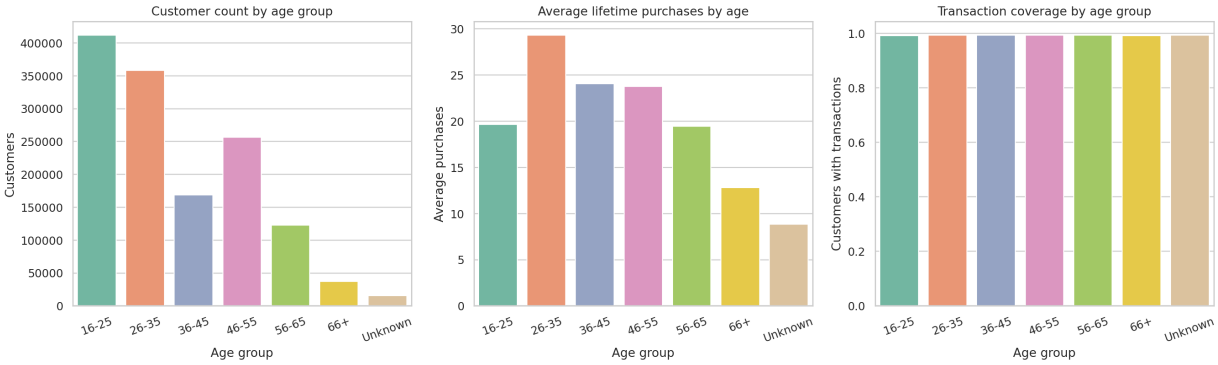


图 7: 年龄画像

5 召回方法

5.1 时间衰减复购

对用户 u 与商品 i 定义

$$s_{ui} = \log(1 + n_{ui})\, \alpha^{\Delta t_{ui}}, \qquad \alpha = 0.985, \tag{1}$$

其中 n_{ui} 为历史购买次数，Δt_{ui} 为预测开始日前距最近购买天数。对数减弱极端高频，指数衰减体现近期兴趣。参数选择依据：图6显示复购间隔分布较宽，图17显示近期度呈长尾分布，因此取近 180 天窗口并令衰减系数为 0.985；附录中的衰减系数评估图（图18）进一步表明，0.985 对应的 Recall@12 优于更小的衰减系数。

5.2 购物篮关联规则

近 180 天历史按同天或同周组篮，统计二商品共现，对规则 $A \to B$ 计算

$$\text{support}(A, B) = \frac{N(A \cap B)}{N}, \tag{2}$$

$$\text{confidence}(A \to B) = \frac{N(A \cap B)}{N(A)}, \tag{3}$$

$$\text{lift}(A \to B) = \frac{N(A \cap B)/N(A)}{N(B)/N}. \tag{4}$$

支持度表共同出现频率，置信度表含 A 时也含 B 的比例，提升度用于排除单纯由 B 热门造成的误读。本文以篮自连接方式统计商品对，每个前件保留至多 20 条规则，未采用完整的 Apriori/FP-Growth 实现。同天篮保留 2 至 20 件、同周篮保留 2 至 30 件，由此得到的规则量分别为 826,891 与 852,677 条。选择依据：图5显示多商品篮足以支撑共现；附录中的关联规则粒度比较图（图20）显示同天与同周 Recall 接近，最终采用同天规则，同周规则仅作对比探索。

5.3 SVD 隐式协同过滤

以近 60 天购买构建用户—商品稀疏矩阵，权重

$$x_{ui} = \log(1 + n_{ui})\, 0.995^{\Delta t_{ui}}, \tag{5}$$

矩阵含 398,740 名用户、36,700 件商品、2,108,074 个非零元，密度约 0.0144%。随机化 SVD 提取 64 维商品向量，按余弦相似度取近邻

$$\mathrm{sim}(i,j) = \frac{\boldsymbol{v}_i^\top \boldsymbol{v}_j}{\|\boldsymbol{v}_i\|\|\boldsymbol{v}_j\|}, \tag{6}$$

每商品至多保存 10 个近邻。用户购过某商品后经近邻获得未购相似商品。该方法利用了共同购买行为来构造相似度。

5.4 人群热门与候选融合

年龄分群热门提供人群偏好，全局近期热门提供基础覆盖；年龄分组为规则离散化。

表 2: 五路召回配置

通道	每用户上限	权重
时间衰减复购	50	1.00
同天关联	20	0.70
隐式协同过滤	20	0.50
年龄分群热门	30	0.45
近 7 天全局热门	30	0.20

以通道内排名 r_{uic} 与权重 w_c 融合：

$$\mathrm{poolScore}(u,i) = \sum_{c \in C(u,i)} \frac{w_c}{r_{uic}}. \tag{7}$$

去重后每人至多 100 件。候选池共 6,047,766 行，覆盖 68,984 名目标周顾客，人均 87.67 件；全体目标周顾客上 Recall@100 为 0.124244、HitRate@100 为 0.246014。

6 特征工程与学习排序

最终使用 26 个数值特征与 5 个类别特征共 31 维，覆盖六方面。

表 3: 特征体系（合计 31 维）

方向	代表特征
用户–商品	时间衰减分、距上次购买天数、历史购买均价
商品热度	不同窗口销量、购买人数、价格总和与热度趋势
类目亲和	用户品类购买次数、颜色购买次数、大类丰富度
用户画像	年龄、年龄组、历史购买量、活跃天数与近期度
价格匹配	用户均价、中位价、价格比与匹配分
召回信息	融合得分、协同过滤分与全局热门分

类别特征为商品部门、颜色、商品类型、用户近期度组与年龄组；数值缺失与无穷值置 -1。模型按顾客构成查询组，用 LightGBM LambdaRank 学习候选相对顺序。超参：学习率 0.03、叶子 63、最小叶样本 100、特征采样 0.85、样本采样 0.90、种子 2026，最多 500 轮、80 轮早停，以 NDCG@12 监控，最优轮数 226。模型输出为排序分数，本文不将其视为校准概率；由于 LambdaRank 面向排序目标，早停使用 NDCG@12 作为监控指标。

7 实验设置与评估

7.1 标签与划分

历史区间 2018-09-20 至 2020-09-15，目标周 2020-09-16 至 22。目标周真实购买记录即 Ground Truth，按用户—商品去重；候选在目标周被购则标签 1，否则 0，后者表“该周未购”而非明确不喜欢。目标周共 68,984 名购买顾客、213,728 个用户—商品组合。按顾客键模 10 划分约 80% 训练（55,265 人）与 20% 验证（13,719 人）。

7.2 Baseline 设置

为检验多路召回与学习排序的增益，本文设置两组规则基线，并与最终模型使用相同的验证用户集合、目标周和 Top-12 截断规则。Baseline 1 为“近期复购 + 窗口热门”方案：依次检查用户最近 7 天、14 天和 21 天的购买记录，优先推荐最近窗口内购买次数较多且购买时间较近的商品，并以相应窗口的热门商品补足列表；若用户没有近期购买记录，则直接使用近 7 天热门商品。Baseline 2 为“近期历史购买 + 同天共现搭配 + 热门兜底”方案：先推荐用户最近 7 天购买过的商品，再依据同一天购物篮中的共现关系为历史商品补充搭配商品，最后仅对没有候选的用户使用近 7 天热门商品兜底。两组基线均采用固定规则生成推荐列表，不训练排序模型；最终方案则在多路召回候选上使用 LightGBM LambdaRank 进行学习排序。

7.3 评估指标

单一指标无法同时刻画“命中与否、命中多少、排得多前、全局区分度”，因此同时使用 MAP@12、Recall@12、HitRate@12 和 AUC。设 T_u 为用户 u 在目标周实际购买的商品集合，$\mathrm{rel}_u(r)$ 表示推荐列表第 r 位商品是否属于 T_u。

MAP@12（Mean Average Precision@12） MAP@12 衡量推荐列表前 12 位中命中商品的排序质量，同时反映命中数量和命中位置。对用户 u，令

$$P_u(r) = \frac{\sum_{j=1}^{r} \mathrm{rel}_u(j)}{r}, \tag{8}$$

表示截至第 r 位的精确率。则用户 u 的 Average Precision 为

$$AP@12(u) = \frac{\sum_{r=1}^{12} P_u(r)\,\mathrm{rel}_u(r)}{\min(12, |T_u|)}, \tag{9}$$

全体用户的 MAP@12 为

$$MAP@12 = \frac{1}{|U|} \sum_{u \in U} AP@12(u). \tag{10}$$

标准公式要求第 r 次命中时使用截至该位置的累计命中数。例如真实商品为 A、B，推荐中分别位于第 1、3 位，则

$$AP = \frac{1/1 + 2/3}{2} = 0.8333. \tag{11}$$

MAP@12 数值越高，表示推荐列表越有效，且越倾向于把命中商品排在前面。

Recall@12（召回率 @12） Recall@12 反映真实购买商品中被前 12 位推荐找回的比例。对每位用户，Recall@12 定义为前 12 位推荐中命中的真实商品数与真实购买商品数之比，再对用户取平均：

$$Recall@12 = \frac{1}{|U|} \sum_{u \in U} \frac{\sum_{r=1}^{12} \mathrm{rel}_u(r)}{|T_u|}. \tag{12}$$

该指标越高，表示推荐列表对用户真实购买商品的覆盖程度越好。

HitRate@12（命中率 @12） HitRate@12 只判断用户是否至少命中一件商品，不区分命中数量。其定义为

$$HitRate@12 = \frac{1}{|U|} \sum_{u \in U} \mathbb{I}\left(\sum_{r=1}^{12} \mathrm{rel}_u(r) > 0 \right), \tag{13}$$

其中 $\mathbb{I}(\cdot)$ 为示性函数，条件成立时取 1，否则取 0。该指标反映至少命中一件商品的用户比例，数值越高表示更多用户在前 12 位推荐中获得了有效命中。

AUC（Area Under Curve） AUC 在候选商品中比较正负样本的相对得分，反映模型将购买候选排在未购买候选之前的整体能力。设 P 为目标周购买的正候选集合，N 为未购买的负候选集合，$s(i)$ 为模型对候选 i 的得分，则

$$AUC = \frac{1}{|P||N|} \sum_{i \in P} \sum_{j \in N} \left[\mathbb{I}(s(i) > s(j)) + \tfrac{1}{2}\mathbb{I}(s(i) = s(j)) \right]. \tag{14}$$

因此，AUC 表示随机抽取一对正负候选时，模型把正候选排在负候选之前的概率；平分时计半次。AUC 越高，表示模型对正负候选的全局区分能力越强。

单一指标无法覆盖推荐效果的全部方面。例如，若 100 件候选中唯一正样本排在第 13 位，它可能超过 87 个负样本，AUC 约为 $87/99 = 0.879$，但 AP@12 仍为 0。因此本文同时报告 MAP@12、Recall@12、HitRate@12 和 AUC，分别评价排序质量、覆盖程度、用户命中比例和候选区分能力，避免用单一指标描述推荐系统。

8 结果与分析

8.1 实验结果

本文在同一验证用户集合上对比两组规则基线与最终 LambdaRank 排序模型。评价时，Ground Truth 为目标周真实购买商品，标准 MAP@12 使用累计命中数计算。三组方法的结果如表4所示。最终模型 AUC 为 0.822039，将在分析部分讨论。

表 4: 同一验证用户集合上的结果

方法	MAP@12	Recall@12	HitRate@12
Baseline 1	0.027734	0.053061	0.102631
Baseline 2	0.024914	0.050712	0.097748
LambdaRank	**0.038758**	**0.075664**	**0.144981**

表4中, LambdaRank 在三项指标上均高于两组基线。以 MAP@12 为例, 最终模型相对 Baseline 1 提高约 39.75%，相对 Baseline 2 提高约 55.57%；Recall@12 和 HitRate@12 也呈现一致趋势，说明排序模型不仅提升了命中商品的排序位置，也扩大了真实购买商品的召回覆盖，并使更多用户在前 12 位推荐中至少命中一件商品。

Baseline 1 的三项指标均高于 Baseline 2，说明共现规则的加入方式与融合策略仍需通过验证集检验；规则数量或形式增加并不必然带来稳定增益。最终模型 HitRate@12 约为 14.50%，即约 14.50% 的验证用户在前 12 位推荐中至少命中一件真实购买商品；Recall@12 约为 7.57%，即用户真实购买商品的平均召回比例约为 7.57%。考虑到候选规模较大且目标周购买行为稀疏，上述绝对数值不高，但相对基线的提升较为明显。

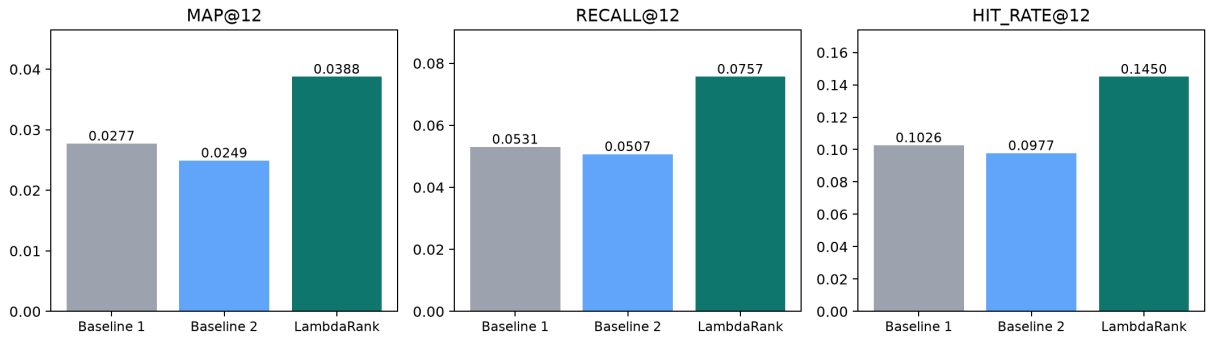


图 8: 基线与最终模型的验证指标

图8直观展示了三组方法在各项指标上的差异。LambdaRank 在 MAP@12、Recall@12 和 HitRate@12 上均取得最高值, 且三项指标的变化方向一致, 表明排序模型带来的增益并非仅体现在单一评价维度上，而是在排序质量、召回覆盖和用户命中比例方面均有体现。

8.2 分析

从特征重要性来看，增益重要性较高的特征包括用户—商品时间衰减分、商品部门、近 14 天购买人数、候选融合得分与颜色。这与前文关于复购行为、商品语义和近期热度的分析相一致：时间衰减分刻画了用户近期购买行为对当前推荐的直接影响，商品部门与颜色提供了商品语义层面的区分信息，近 14 天购买人数则反映了近期热度信号，而候选融合得分综合了多路召回的信息。这些特征分别对应近期偏好、商品属性和候选覆盖信息，使排序模型可以综合多类信号。

在全局区分能力方面，最终模型的候选级 AUC 为 0.822039，表示随机抽取一条正候选和一条负候选时，模型将正候选排在前面的概率约为 82.20%。这说明模型在候选级别上对购买候选

与未购买候选具有较好的整体区分能力。AUC 衡量全局排序能力，而 MAP@12、Recall@12 和 HitRate@12 更关注前 12 位的实际效果，因此两类指标需要结合解读。LambdaRank 的 AUC 较高，同时前 12 位指标也优于基线，说明其全局区分能力在前 12 位推荐中同样有所体现。

8.3 结论

综合实验结果与分析，本文得到以下结论：

（1）五路召回中，时间衰减复购的权重最高，且在特征重要性中排名靠前，是近期行为的主要信号来源；固定融合策略扩大了候选覆盖，为后续排序模型提供了更充分的候选基础；

（2）LambdaRank 在统一验证集上优于两组规则基线，MAP@12 达到 0.038758，相对 Baseline 1 和 Baseline 2 分别提高约 39.75% 和 55.57%，Recall@12 与 HitRate@12 也同步提升，表明排序模型在命中数量、命中位置和用户覆盖方面均带来增益；

（3）探索分析为召回规则和排序特征提供依据，模式挖掘与多路召回扩大候选覆盖，LambdaRank 完成候选排序，三者对应本文从数据分析到推荐输出的主要流程。

附录：补充分析图

正文未展开的探索分析图和模式挖掘图集中列于附录，用于补充数据证据。

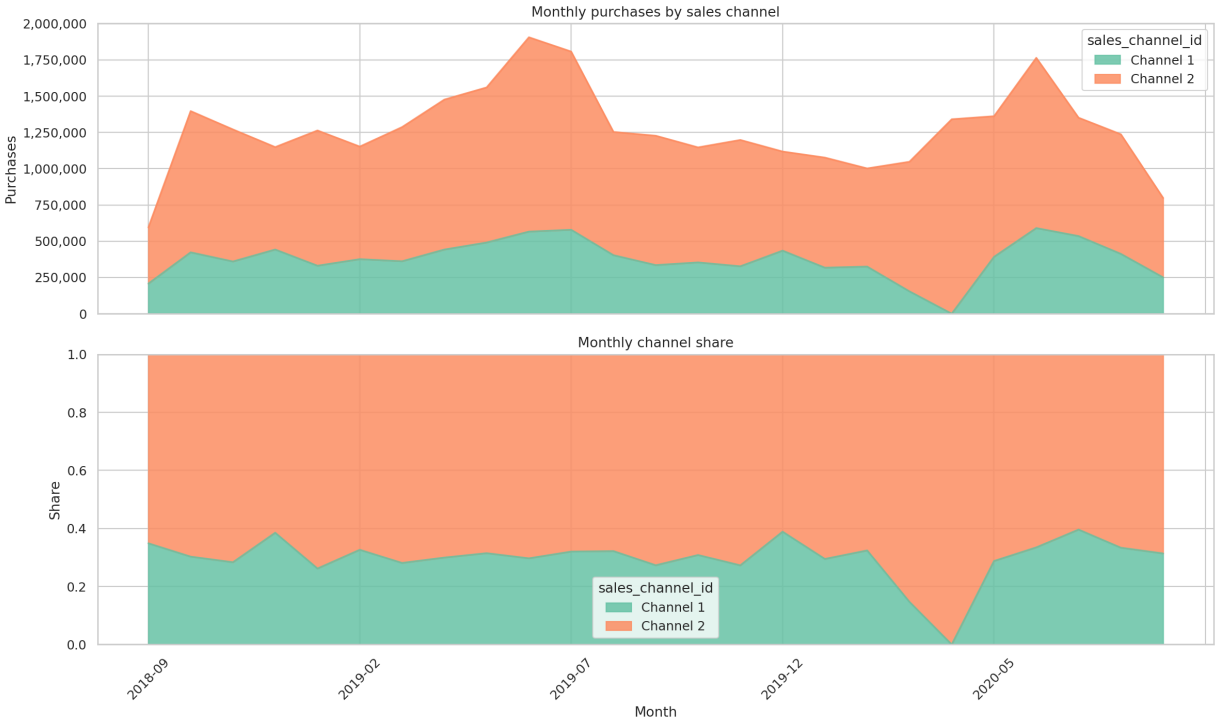


图 9: 月度渠道占比

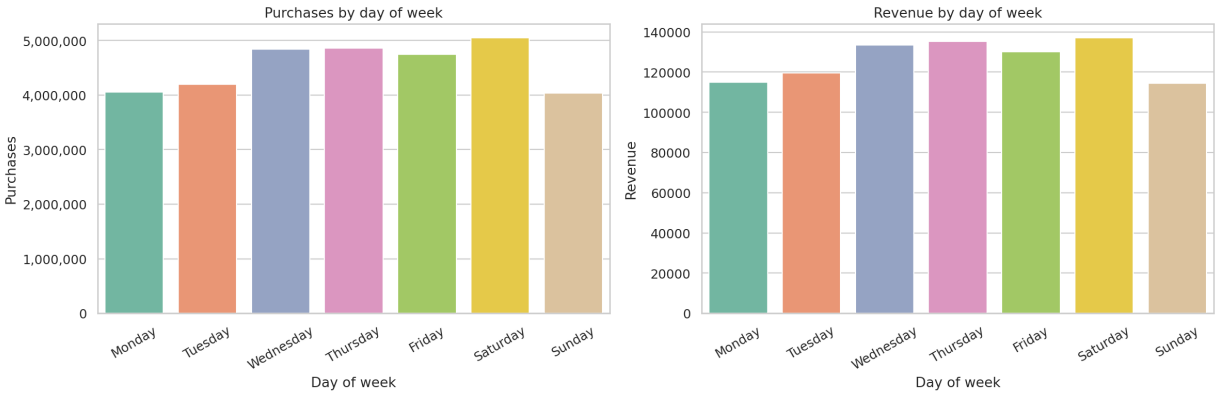


图 10: 星期交易模式

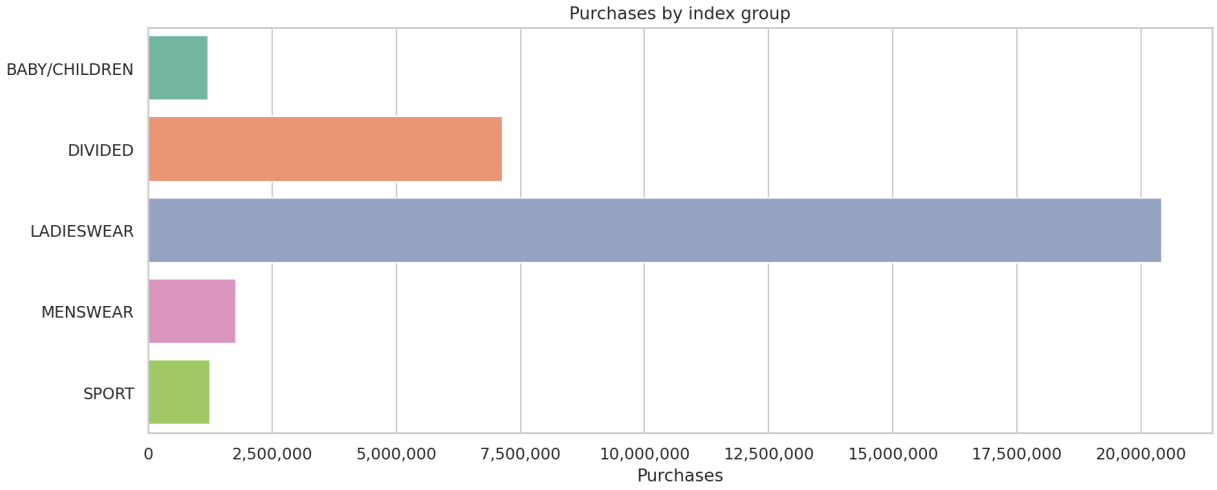


图 11: 大类购买量

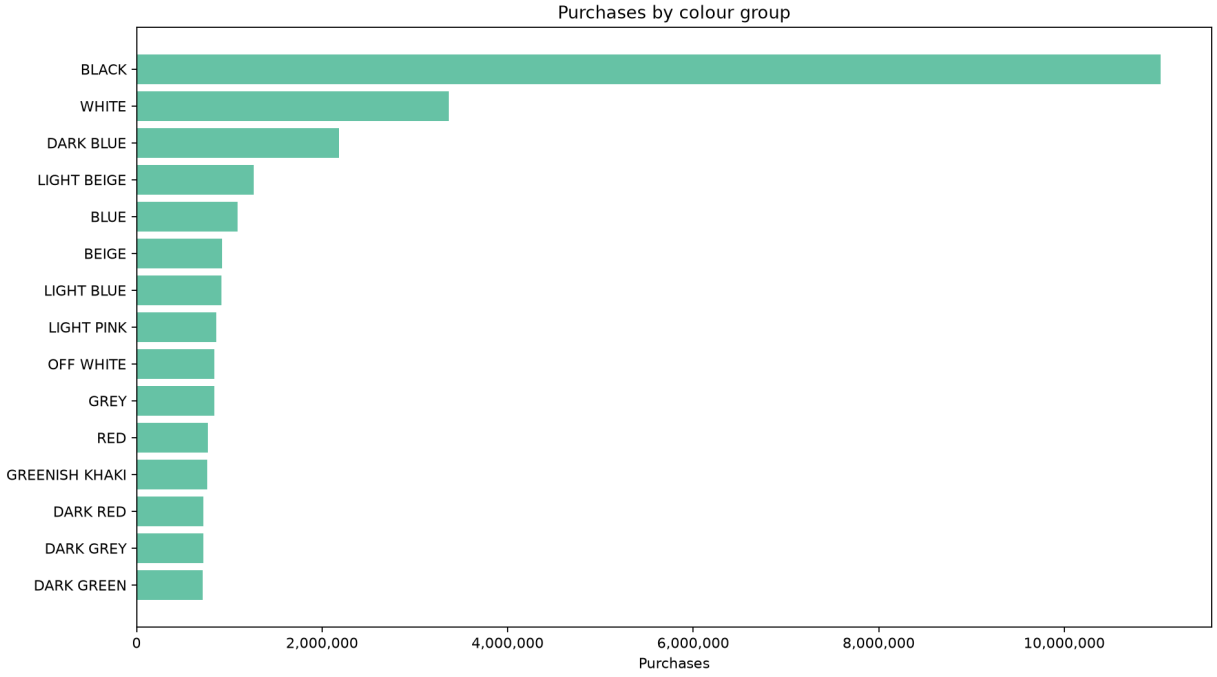


图 12: 颜色购买量

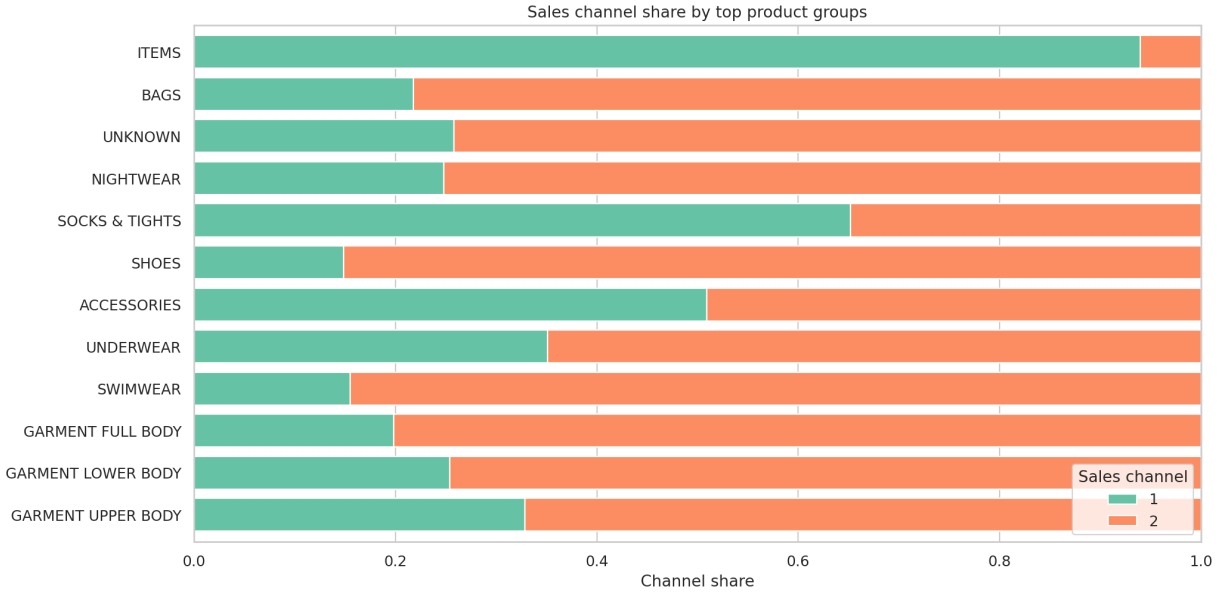


图 13: 品类渠道构成

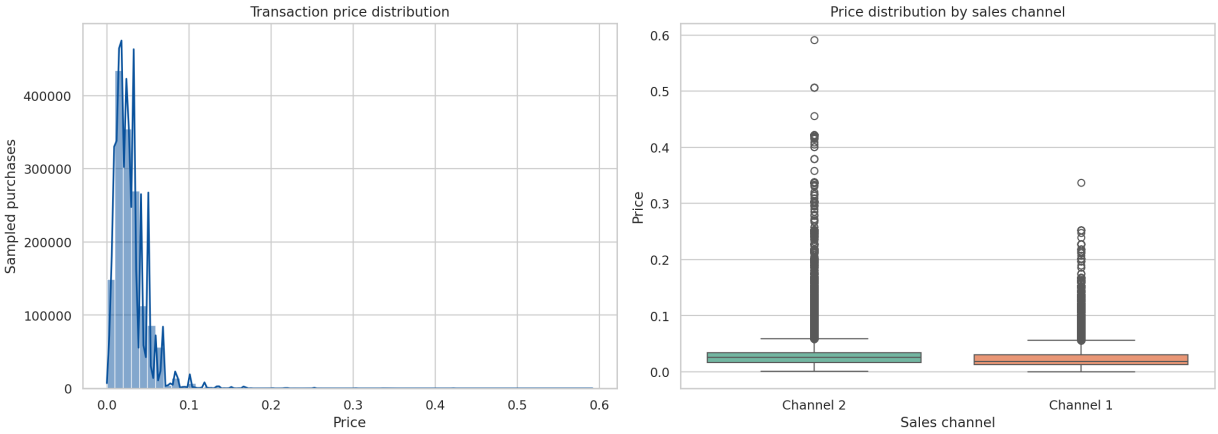


图 14: 价格分布

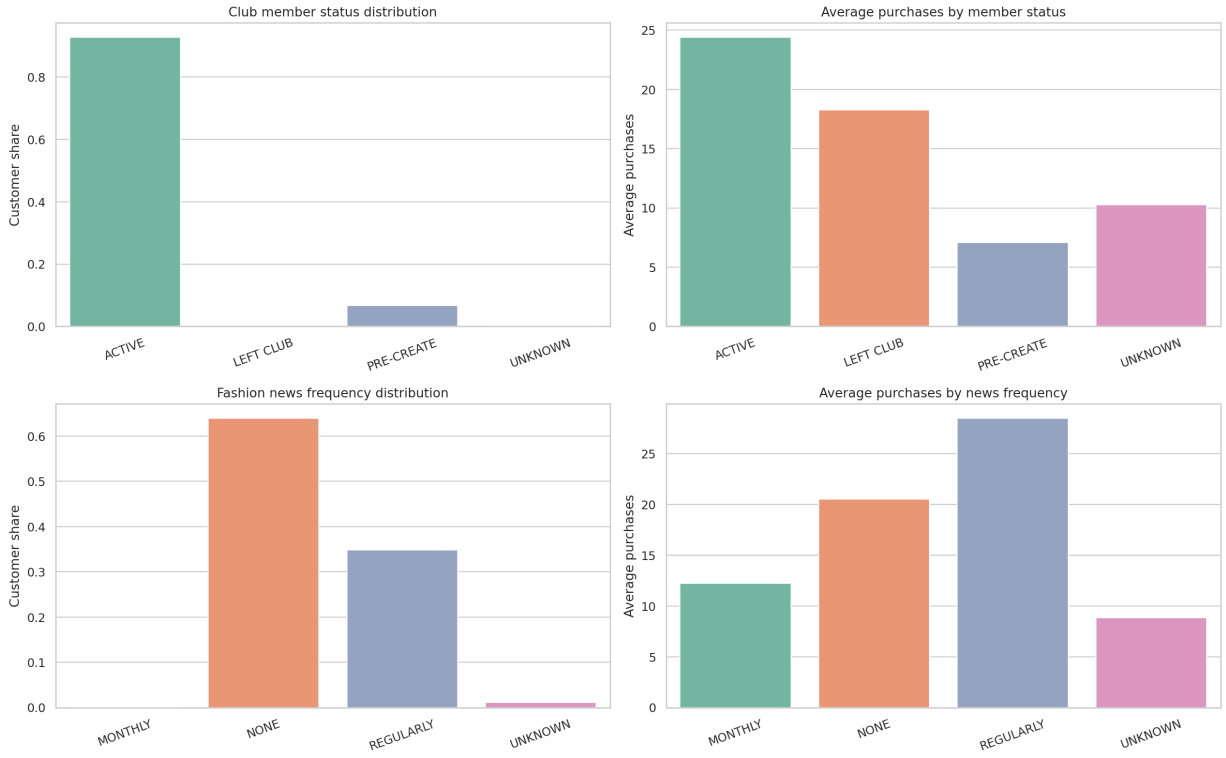


图 15: 会员与订阅画像

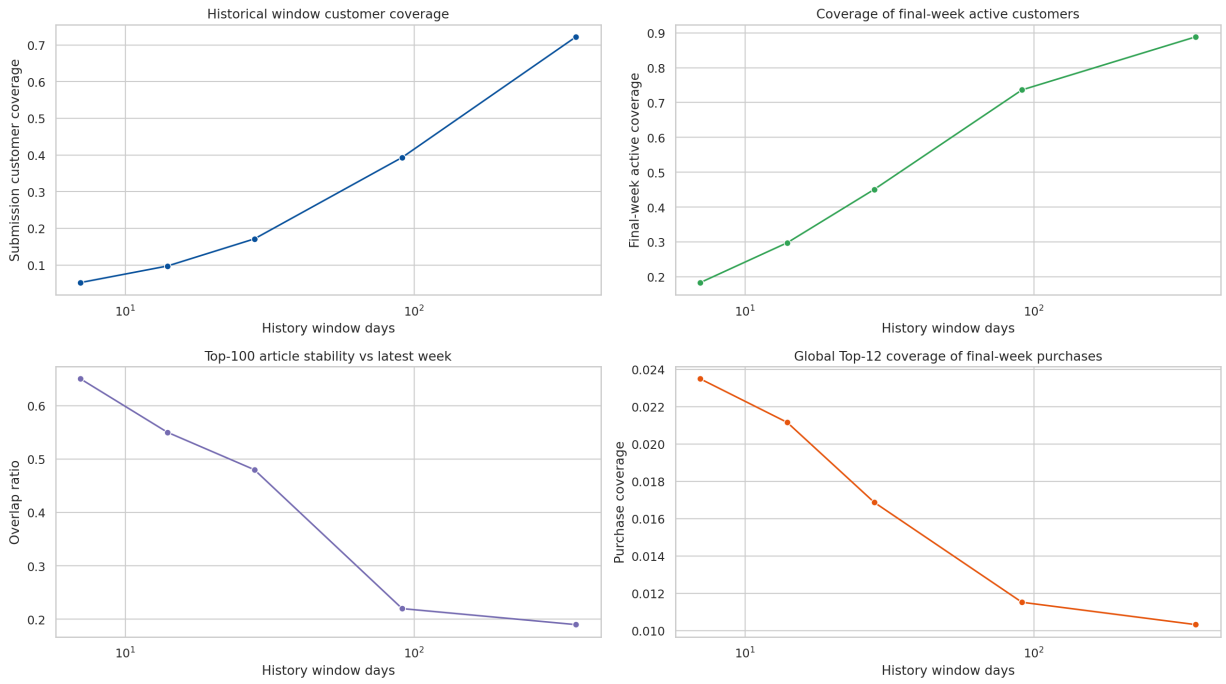


图 16: 窗口覆盖稳定性



图 17: 顾客近期度分布

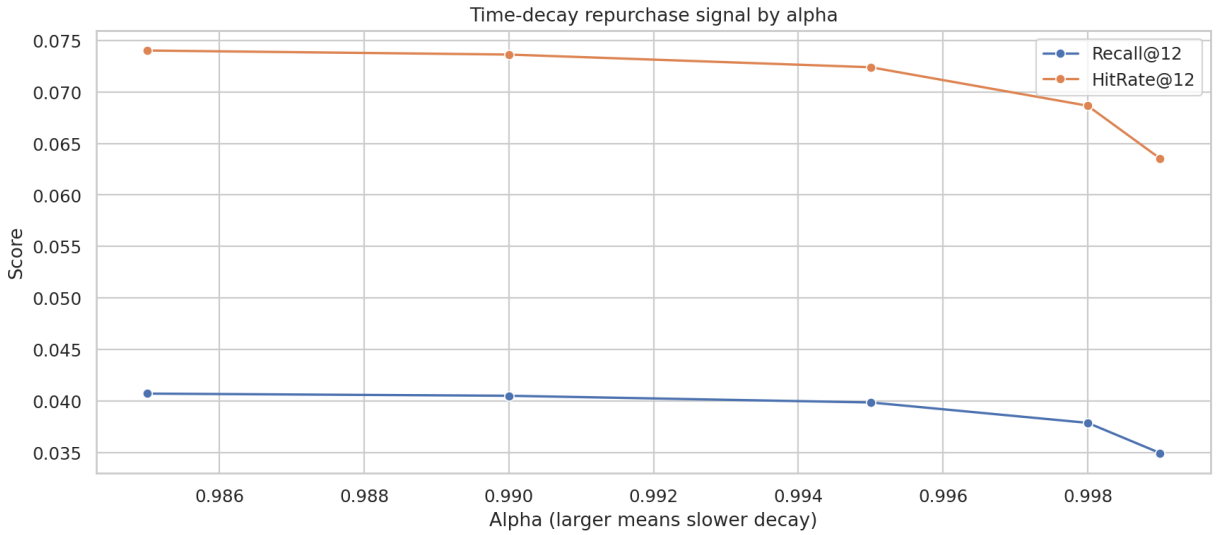


图 18: 衰减系数评估

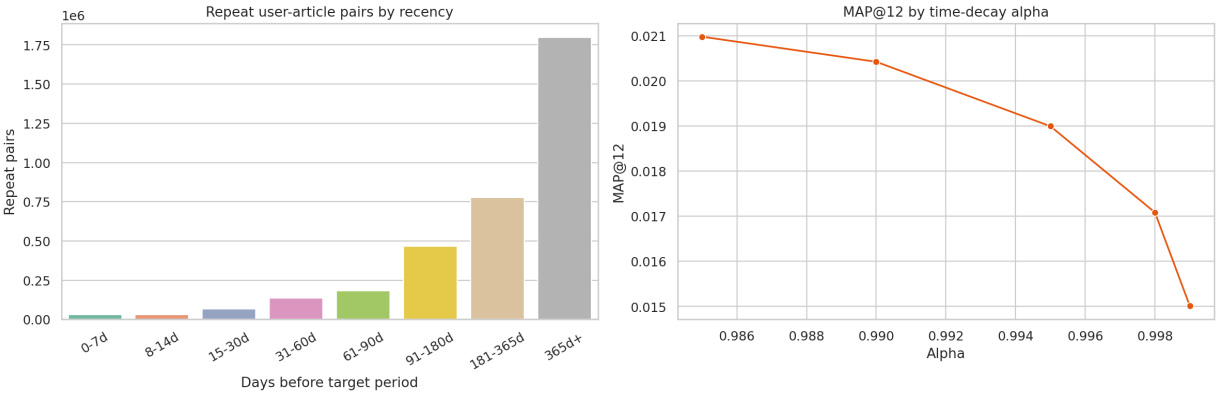


图 19: 复购间隔分布

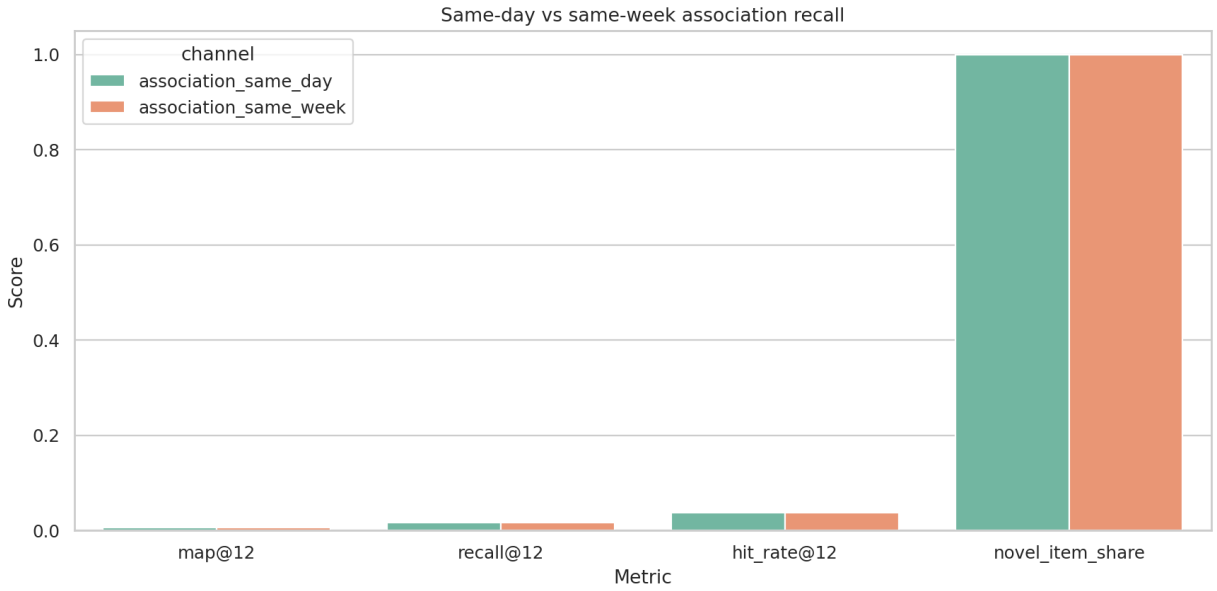


图 20: 关联规则粒度比较

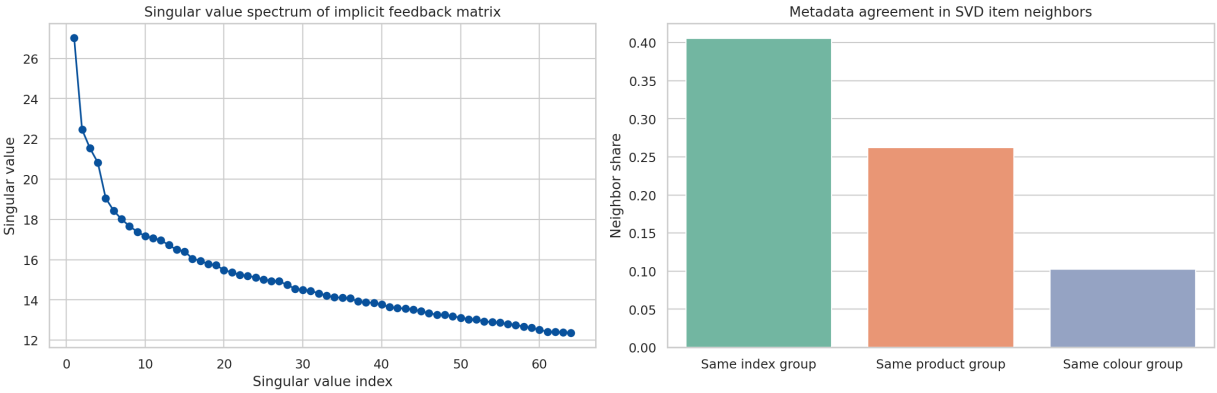


图 21: SVD 奇异值

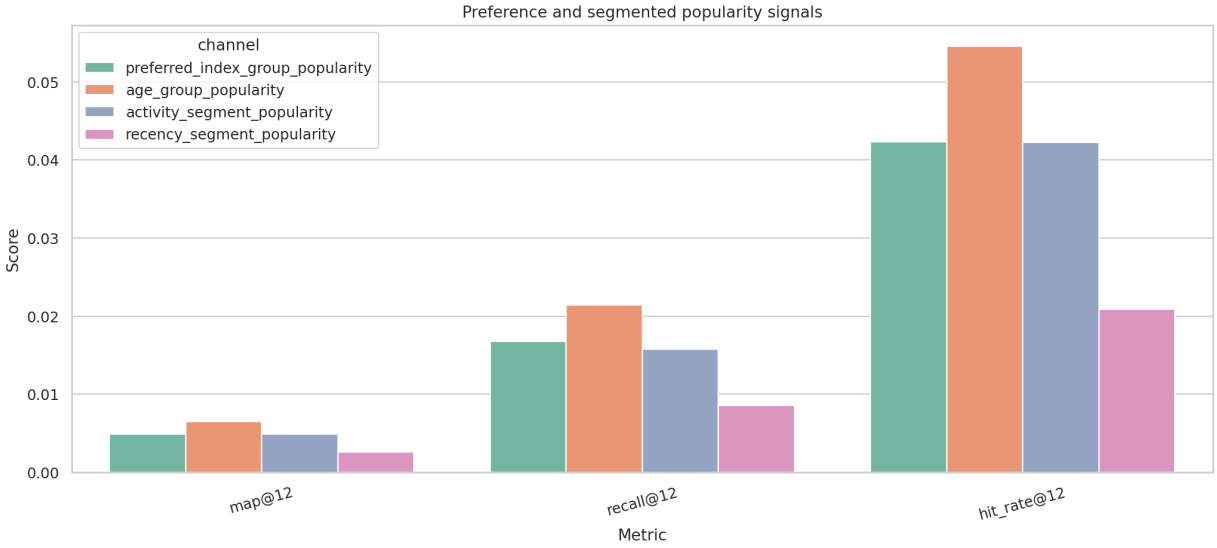


图 22: 画像通道比较

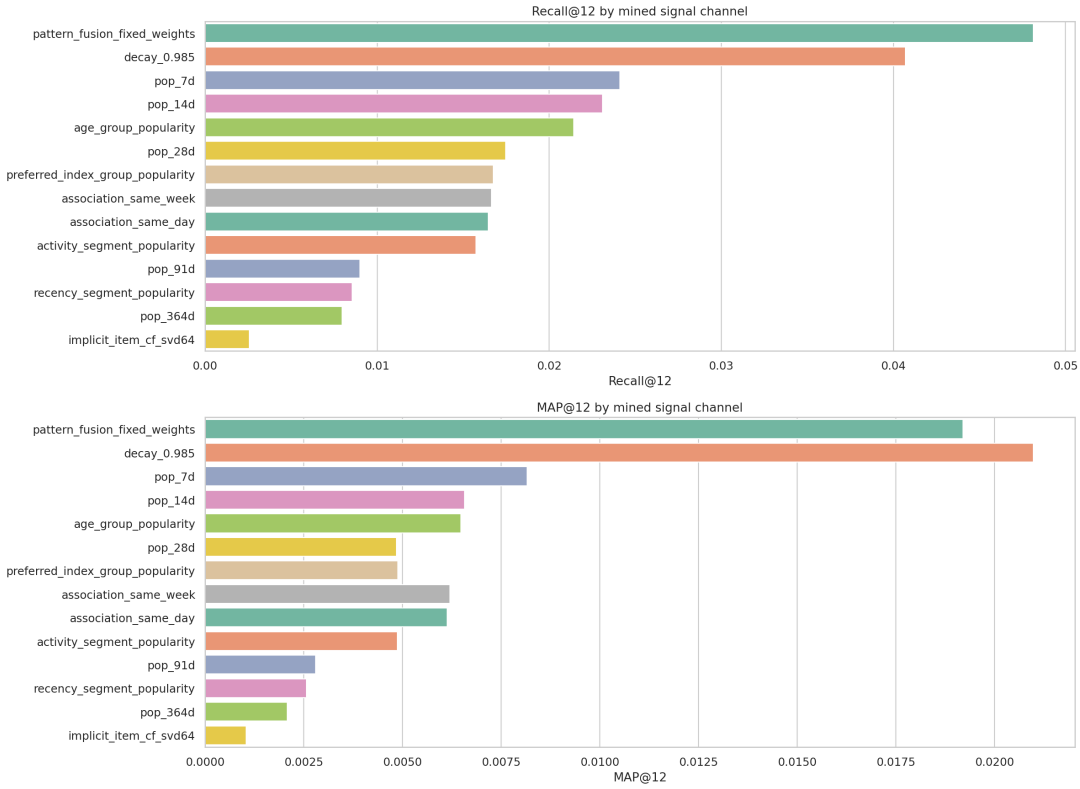


图 23: 通道融合评估

参考文献

[1] R. Agrawal and R. Srikant. Fast algorithms for mining association rules in large databases. In Proceedings of the 20th International Conference on Very Large Data Bases, pp. 487–499, 1994.

[2] B. Sarwar, G. Karypis, J. Konstan, and J. Riedl. Item-based collaborative filtering recommendation algorithms. In Proceedings of the 10th International Conference on World Wide Web, pp. 285–295, 2001.

[3] Y. Koren, R. Bell, and C. Volinsky. Matrix factorization techniques for recommender systems. Computer, 42(8):30–37, 2009.

[4] C. Burges, T. Shaked, E. Renshaw, A. Lazier, G. Deidsch, N. Hamilton, G. Hullender, J. Phillips, and B. Vapnik. Learning to rank using gradient descent. In Proceedings of the 22nd International Conference on Machine Learning, pp. 89–96, 2005.

[5] C. J. C. Burges. Learning to rank with nonsmooth cost functions. In Advances in Neural Information Processing Systems, Vol. 19, 2006.

小组成员分工

本项目由三位小组成员共同完成。全体成员共同参与了选题讨论、研究方案设计及实验结果分析。具体分工负责情况如下表所示。

表 5: 小组成员分工

成员	主要职责	具体工作内容	贡献比例
梁潇颖	数据分析与代码实现	负责数据预处理、探索性数据分析、数据挖掘算法实现、实验评估及结果可视化。	0.33
吕梦月	报告撰写与整理	负责相关背景调研、方法与实验结果整理、报告撰写、图表说明及全文修改。	0.33
郑旭阳	展示与成果汇报	负责实验结果总结、PPT 设计与制作、汇报内容组织及课堂展示。	0.33